

KLASIFIKASI KEMACETAN PADA PERSIMPANGAN BUAH BATU MENGGUNAKAN METODE ARTIFICIAL NEURAL NETWORK

Tugas Akhir
diajukan untuk memenuhi salah satu syarat
memperoleh gelar sarjana
dari Program Studi Informatika
Fakultas Informatika
Universitas Telkom

1301162766

Putri Enita



Program Studi Sarjana Informatika
Fakultas Informatika
Universitas Telkom
Bandung

2020

LEMBAR PENGESAHAN

KLASIFIKASI KEMACETAN PADA PERSIMPANGAN BUAH BATU MENGUNAKAN METODE ARTIFICIAL NEURAL NETWORK

*Classification of Congestion in Buah Batu Intersections Using the Artificial Neural
Network Method*

NIM: 1301162766

Putri Enita

Tugas akhir ini telah diterima dan disahkan untuk memenuhi sebagian syarat memperoleh
gelar pada Program Studi Sarjana Informatika

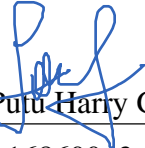
Fakultas Informatika

Universitas Telkom


Bandung, 10 Agustus 2020

Menyetujui


Pembimbing I


Dr. Putu Harry Gunawan, S.Si., M.Si., M.Sc.
NIP: 16860043

Pembimbing II


Dr. Kemas Maslim Lhaksmana, S.T., M.Isd.
NIP: 13820075

Ketua Program Studi
Sarjana Informatika,


Niken Dwi Wahyu Cahyani, S.T., M.Kom.
NIP: 007500152

LEMBAR PERNYATAAN

Dengan ini saya, Putri Enita, menyatakan sesungguhnya bahwa Tugas Akhir saya dengan judul ” **KLASIFIKASI KEMACETAN PADA PERSIMPANGAN BUAH BATU MENGGUNAKAN METODE ARTIFICIAL NEURAL NETWORK** ” beserta dengan seluruh isinya adalah merupakan hasil karya sendiri, dan saya tidak melakukan penjiplakan yang tidak sesuai dengan etika keilmuan yang berlaku dalam masyarakat keilmuan. Saya siap menanggung resiko/sanksi yang diberikan jika dikemudian hari ditemukan pelanggaran terhadap etika keilmuan dalam buku TA atau jika ada klaim dari pihak lain terhadap keaslian karya.

Bandung, 10 Agustus 2020

Yang Menyatakan,



Putri Enita

KLASIFIKASI KEMACETAN PADA PERSIMPANGAN BUAH BATU MENGGUNAKAN METODE ARTIFICIAL NEURAL NETWORK

Putri Enita¹, Putu Harry Gunawan², Kemas Muslim Lhaksana³

^{1,2,3}Fakultas Informatika, Universitas Telkom, Bandung

⁴Divisi Digital Service PT Telekomunikasi Indonesia

¹putrienita@student.telkomniversity.ac.id, ²phgnawan@telkomniversity.ac.id,

³kemasmuslim@telkomniversity.ac.id

Abstrak

Kendaraan bermotor merupakan suatu alat transportasi yang sering digunakan oleh masyarakat diberbagai kota besar, salah satunya di Kota Bandung. Jumlah kendaraan yang terus meningkat menjadi salah satu faktor penyebab terjadinya kemacetan. Solusi dalam menangani kemacetan tersebut perlu dilakukan penanganan khusus seperti manajemen lalu lintas. Untuk memudahkan dalam proses manajemen lalu lintas, maka perlu dilakukan klasifikasi kemacetan. Pada penelitian ini dilakukan klasifikasi kemacetan khususnya di persimpangan Buah Batu. Metode yang digunakan ialah Artificial Neural Network, kemudian data set dibagi menjadi 2 bagian yaitu sebanyak 80% data latih dan 20% data uji. Data jumlah kendaraan berdasarkan waktu merupakan parameter input dan outputnya merupakan hasil klasifikasi yaitu berupa kelas macet atau tidak. Perhitungan klasifikasi menggunakan *5-fold cross-validation*. Setelah dilakukan 13 kali running program, diperoleh nilai rata-rata presisi sebesar 0,887 lalu rata-rata nilai recall sebesar 0,891 kemudian rata-rata nilai f1-score sebesar 0,878 dan rata-rata nilai akurasi adalah 0,931. Pada penelitian ini lebih diutamakan nilai F1-score dibandingkan nilai akurasi, karena pada penelitian ini memiliki data dengan jumlah kelas yang tidak seimbang, serta F1-score memiliki kemampuan dalam menilai model yang dibuat itu apakah kedua kelas diprediksi dengan baik atau tidak.

Kata kunci :kemacetan, klasifikasi, artificial neural network

Abstract

Motorized vehicles are a means of transportation that is often used by people in various big cities, one of which is in the city of Bandung. The number of vehicles that continue to increase becomes one of the factors causing congestion. The solution to deal with congestion needs to be done special handling such as traffic management. To facilitate the traffic management process, it is necessary to classify congestion. In this study, the classification of congestion is carried out, especially at the junction of Buah Batu. The method used is an Artificial Neural Network, then the data set is divided into 2 parts: 80% of training data and 20% of test data. Data on the number of vehicles based on time are input and output parameters which are the result of calcification in the form of a traffic jam or not. The classification calculation uses a 5-fold cross-validation. After running the program 13 times, an average precision value of 0.887 was obtained then an average recall value of 0.891 then an average score of f1-score of 0.878 and an average accuracy value of 0.931. In this study, the F1-score value is prioritized over the accuracy value, because this study has data with an unbalanced number of classes, and F1-score can assess the model made whether the two classes are well predicted or not.

Keywords: congestion, classification, artificial Neural network

1. Pendahuluan

Latar Belakang

Kendaraan bermotor merupakan suatu alat transportasi yang sering digunakan oleh masyarakat diberbagai kota besar, salah satunya di Kota Bandung. Setiap tahunnya jumlah kendaraan bermotor mengalami peningkatan yang cukup drastis. Menurut data Dinas Perhubungan Kota Bandung, kenaikan jumlah kendaraan mencapai sebelas persen pada tahn 2018 yang terdiri dari jumlah kendaraan roda da sebanyak 1.251.080 unit dan jumlah kendaraan roda empat sebanyak 536.973 unit, peningkatan tersebt diprediksi akan terus bertambah hingga beberapa tahun kedepan [1] [8]. Peningkatan jumlah kendaraan tersebt menjadi salah satu faktor penyebab terjadinya kemacetan di

sejumlah ruas jalan di Kota Bandung. Solusi dalam menangani kemacetan menurut Peraturan Menteri Perhubungan RI No 96 Tahun 2015, perlu dilakukan penanganan khusus berupa kontrol manajemen lalu lintas seperti rekayasa lalu lintas, pengaturan durasi lampu lalu lintas, dan sebagainya [3]. Untuk mempermudah dalam manajemen lalu lintas, maka dilakukan klasifikasi kemacetan yang sering terjadi terutama di persimpangan jalan yang terdapat lampu lalu lintas.

Terdapat beberapa penelitian telah dilakukan untuk mengklasifikasikan kemacetan pada lalu lintas, diantaranya pada paper [9],[13], dan [15]. Pada paper [9], dilakukan untuk memprediksi suatu jalan yang rentan mengalami kemacetan berdasarkan jumlah pengguna kendaraan menggunakan algoritma komputasi cerdas, *multi layer perceptron*, *k-means* dan *particle swarm optimization* (PSO) dengan hasil terbaik diperoleh dari algoritma *mltilayer perceptron*. Pada paper [13], penelitian dilakukan menggunakan algoritma Jaringan Saraf Tiruan yaitu Metode *Backpropagation* dengan memprediksi jumlah kendaraan khususnya di protokol jalan DKI Jakarta. Sedangkan pada paper [15], dilakukan penelitian untuk memprediksi data arus lalu lintas di Jepara menggunakan metode *Neural Network* dengan memperoleh nilai RMSE sebesar 1,092. Berdasarkan ketiga referensi tersebut, maka pada tgas akhir ini dilakukan klasifikasi kemacetan menggunakan metode *Artificial Neural Network* atau ANN khususnya pada persimpangan Buah Batu Kota Bandung. Metode ANN dipilih karena metode tersebut memiliki keunggulan dalam *learning rate* yang berfungsi untuk memprediksi dengan memperoleh nilai error yang kecil.

Data diperoleh dari Dinas Perhubungan Kota Bandung melalui observasi secara langsung terhadap jumlah kendaraan yang melintasi pada keempat titik lokasi di Persimpangan. Jenis kendaraan yang dihitung ialah kendaraan berat, kendaraan ringan, dan kendaraan tidak bermesin. Pada data terdapat atribut yaitu hari, waktu, lokasi, serta jumlah kendaraan, kemudian terdapat dua kelas yaitu 0 artinya tidak macet, dan 1 artinya macet.

Adapun tujuan yang dicapai yaitu untuk membangun suatu sistem dalam melakukan klasifikasi kemacetan pada persimpangan Buah Batu, sehingga dapat mempermudah dalam melakukan kontrol manajemen lalu lintas yang berfungsi sebagai solusi penanganan kemacetan pada persimpangan, lalu sistem ini juga dapat digunakan pada persimpangan-persimpangan lainnya. Kemudian dapat menganalisis performansi dari hasil klasifikasi kemacetan menggunakan metode *Artificial Neural Network*.

2. Studi Terkait

2.1 Artificial Neural Network

Artificial Neural Network (ANN) atau Jaringan Syaraf Tiruan merupakan teknik pengolahan informasi yang terinspirasi oleh cara kerja sistem syaraf biologis pada sel otak manusia dalam memproses informasi. Dalam ANN terdapat elemen pengolahan berupa suatu model tiruan dari *neron* yaitu *perceptron* [11] [2].

Cara kerja *Artificial Neural Network* adalah informasi dikirim ke *perceptron* dengan bobot tertentu, diproses oleh suatu fungsi yang akan menjumlahkan nilai-nilai bobot yang sudah tersedia. Hasil dari penjumlahan tersebut akan dibandingkan dengan nilai ambang tertentu melalui fungsi aktivasi pada setiap *neuron*. Jika *input* melewati suatu nilai ambang tertentu *neron* akan aktif, begitupun sebaliknya. Apabila *neuron* aktif akan mengirim *output* melalui bobot *output*-nya ke *neuron* yang terhubung [6] [5].

2.1.1 Perceptron

Perceptron merupakan sel saraf atau *neuron* buatan yang dimodelkan secara sederhana. Perceptron terdiri dari single layer dan multilayer [14]. Perceptron single layer memiliki struktur input layer dan output layer, sedangkan perceptron multilayer memiliki satu atau lebih hidden layer berfungsi untuk mentransformasikan data input yang secara linear tidak dapat dipisahkan [10].

Parameter input berupa x_1, x_2, \dots, x_d serta nilai *weight* atau bobot berupa w_1, w_2, \dots, w_d pada *single layer* diolah menggunakan fungsi aktivasi untuk menghitung nilai outputnya. Sedangkan pada multilayer, hasil perhitungan nilai input dan nilai *weight* yang diperoleh secara random menghasilkan nilai hidden layer. Kemudian nilai hidden layer tersebut dihitung dengan bobot miliknya dan menjadi nilai dari hidden layer selanjutnya sampai pada akhirnya menjadi nilai output [4].

2.1.2 Backpropagation

Backpropagation merupakan metode yang optimal dalam menyelesaikan masalah berbentuk pola-pola kompleks. Metode ini menurunkan gradien untuk meminimalkan nilai error dalam penjumlahan kuadrat output jaringan [16] [13]. Cara kerja backpropagation yaitu parameter input dan output target dimasukkan ke dalam jaringan yang akan menghasilkan output aktual. Selanjutnya output aktual dibandingkan dengan output target agar mengetahui apakah sudah sesuai atau belum, apabila belum sesuai maka menghasilkan nilai error atau loss yang kemudian

dihitung dan digunakan untuk me-update nilai w yang relevan dengan dilakukan *backpropagation* menggunakan derivative fungsi aktivasi [4] [16].

2.1.3 Fungsi Aktivasi

Fungsi aktivasi merupakan suatu fungsi yang digunakan dalam tahap perhitungan nilai output. Karakteristik yang dimiliki oleh fungsi aktivasi ialah continue, diferensiabel dan tidak menurun secara monoton serta diharapkan mendekati nilai-nilai maksimum dan minimum secara asimtot [10]. fungsi aktivasi terdiri dari fungsi Sigmoid, fungsi Tanh, dan fungsi Relu [14] [10].

1. Fungsi Sigmoid

Fungsi sigmoid merupakan fungsi yang paling umum digunakan serta memiliki rentang nilai dari 0 sampai 1. fungsi ini dapat digunakan pada sistem yang menggunakan backpropagation, serta pada jaringan yang membutuhkan nilai output dengan rentang nilai 0 sampai 1. Fungsi sigmoid didefinisikan seperti pada Persamaan (1).

$$f(x) = \frac{1}{1 + e^{-x}} \quad (1)$$

2. Fungsi Tanh

Fungsi tanh sering digunakan dalam melakukan klasifikasi dua kelompok data yang memiliki rentang nilai dari -1 hingga 1 secara matematis fungsi tanh ditulis seperti pada Persamaan (2).

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2)$$

3. Fungsi Relu

Pada umumnya fungsi relu digunakan dalam klasifikasi lebih dari dua kelompok data serta memiliki rentang nilai dari 0 sampai tidak terhingga yang didefinisikan seperti pada Persamaan (3).


$$\text{relu} = \max(0, \infty) \quad (3)$$

3. Sistem yang Dibangun

3.1 Data

Data diperoleh dari Dinas Perhubungan Kota Bandung melalui observasi yang dilakukan terhadap empat titik di persimpangan Buah Batu - Soekarno Hatta seperti pada Gambar 1. Titik Timur merupakan arus kendaraan yang melintas menuju arah Jalan Soekarno Hatta - Kiaracondong lalu titik Barat merupakan arus kendaraan yang melintas menuju arah Jalan Soekarno Hatta - Batunnggal, pada titik utara merupakan arus kendaraan yang melintas menuju arah Jalan Buah Batu, dan titik Selatan merupakan arus kendaraan yang melintas menuju arah Jalan Terusan Buah Batu.

Jumlah kendaraan yang dihitung ialah pada saat kendaraan melintas sesuai arah tujuannya dari masing-masing posisi awalnya pada keempat titik di persimpangan tersebut, jumlah kendaraan dihitung setiap 15 menit sekali dimulai pada pukul 07.00 WIB hingga pukul 16.00 WIB dimulai dari hari Senin hingga hari Minggu. Jenis kendaraan yang dihitung ialah kendaraan berat, kendaraan ringan serta kendaraan yang tidak bermotor sehingga diperoleh data yang berjenis supervised dengan jumlah sebanyak 480 record yang terdiri dari 5 atribut yaitu hari, waktu, posisi, jumlah kendaraan lolos serta kapasitas jalan. Lalu terdapat dua jumlah kelas, yang pertama yaitu 0 artinya tidak macet, serta yang kedua ialah kelas 1 yang artinya macet yang dapat dilihat seperti pada Gambar 2.



Gambar 1. Ilustrasi Persimpangan

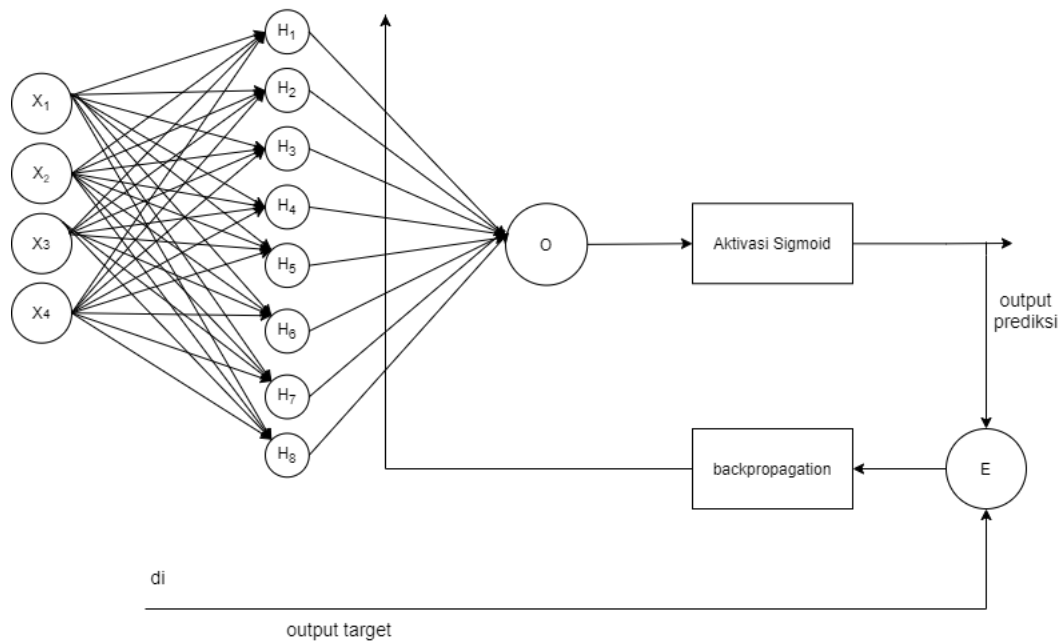
	hari	waktu	posisi	volume_kendaraan_lolos	kapaistas_jalan	level_of_service
0	senin	07:00-08:00	Timur	964	2617	0
1	senin	07:00-08:00	Barat	689	2671	0
2	senin	07:00-08:00	Utara	1592	2514	0
3	senin	07:00-08:00	Selatan	1581	943	1
4	senin	07:15-08:15	Timur	1030	2671	0
...
475	minggu	15:45-16:45	selatan	1983	943	1
476	minggu	16:00-17:00	timur	564	2671	0
477	minggu	16:00-17:00	barat	753	2671	0
478	minggu	16:00-17:00	utara	1246	2514	0
479	minggu	16:00-17:00	selatan	1793	943	1

Gambar 2. Data

3.2 Preprocessing

Sebelum dilakukan proses klasifikasi, data dilakukan proses preprocesing terlebih dahulu yaitu pertama, dilakukan *drop* pada atribut kapasitas jalan, karena atribut kapasitas jalan dengan atribut posisi memiliki nilai dengan makna yang sama. Selanjutnya dilakukan proses label encoding, yaitu proses transformasi label kata menjadi numerik. Pada data ini menggunakan *labelencoder* pada atribut hari, waktu, serta posisi yang dimana ketiga atribut tersebut memiliki data yang berjenis *string*, kemudian ditransformasikan menjadi numerik. Pada atribut hari yang awalnya memiliki data senin hingga minggu ditransformasikan menjadi numerik atau angka 0 hingga 6, lalu pada atribut waktu ditransformasikan menjadi 0 hingga 14, kemudian atribut posisi ditransformasikan menjadi 0 hingga 3 sehingga didapatkan dataset dengan terdapat 4 atribut yaitu hari, waktu, posisi dan volume kendaraan serta 2 kelas 0 (tidak macet) dan 1 (macet) yang siap digunakan pada tahap proses klasifikasi.

3.3 Proses Klasifikasi



Gambar 3. Arsitektur Yang digunakan

Proses klasifikasi menggunakan metode *Artificial Neural Network Backpropagation* dengan melakukan pembagian data atau *splitting* menjadi dua bagian yaitu, data latih dan data uji. Persentase data latih sebesar 80 % dan data uji sebesar 20%. Pada data latih dilakukan pembagian kembali menggunakan *batch size* yang bertujuan untuk mencari akurasi training. Lalu dilakukan training model yang dimulai dari penentuan bobot dengan cara random. Setelah itu dilakukan *looping* penentuan nilai output dengan menggunakan fungsi aktivasi *Sigmoid* dengan rumusan seperti pada Persamaan (1). Tiap-tiap *looping* akan dilakukan *update weight* dengan metode *backpropagation* yang bertujuan agar nilai error semakin kecil. Jumlah *looping* yang dilakukan berdasarkan epoch yang telah ditentukan yaitu 300 kali. Pada sistem ini jumlah hidden layer adalah 1 layer, variabel x pada sigmoid diisi dengan perkalian matrix *dot* antara nilai parameter input dengan bobot *Weight*. Setelahnya dihitung loss atau error yang dihasilkan dari prediksi output dengan Persamaan (4). Setelah mendapatkan akurasi training selanjutnya model yang sudah di *training* akan digunakan untuk menebak data test 20 % yang telah di *split* di awal-awal untuk mencari akurasi uji.


$$Error = output_target - output_prediksi \quad (4)$$

output yang dihasilkan akan memasuki fungsi aktivasi setelah itu mencari nilai error dan nilainya akan dipakai pada tahap *backpropagation* atau pengaturan kembali output prediksinya. Tahap ini memerlukan turunan dari *sigmoid* yaitu *sigmoid derivative* dan nilai *adjustments* untuk mengatur bobot. Sehingga didapatkan rumusan dari *adjustments* pada Persamaan (5). Kemudian dari nilai *adjustments* tersebut ditentukan bobot terupdate dengan perkalian antara matriks input dengan *adjustments*.

$$adjstments = loss * sigmoid_derivative(outputs) \quad (5)$$

3.4 Cross Validation

Pada penelitian tugas akhir ini, digunakan *cross validation* untuk mengukur kinerja model yang telah dibangun dengan merata-ratakan hasil akurasi yang didapatkan berdasarkan jumlah lipatan pada *cross validation*. *Cross validation* merupakan suatu metode dasar yang digunakan untuk melakukan evaluasi hasil prediksi atau hasil pembelajaran dalam bidang *machine learning*[12]. *Cross validation* yang digunakan pada tugas ini sebanyak *5-fold cross validation*, sehingga data di *splitting* menjadi dua bagian seperti pada Gambar 4, kotak berwarna biru merupakan data test sedangkan kotak berwarna putih merupakan data train. Data train sebesar 80% sedangkan data test sebesar 20%, setiap iterasi, pemilihan data test akan berganti-ganti sesuai partisipasinya.



Gambar 4. 5-fold cross validation

3.5 Evaluasi

Pada tugas akhir ini dilakukan evaluasi menggunakan rumus-rumus performansi seperti pada umumnya. Dalam tugas ini kelas positif merupakan kelas 1 yang artinya macet. Seperti pada Tabel 1, sehingga didapatkan rumus presisi, recall, f1-score serta akurasi seperti berikut[7].

y	Predicted Positive	Predicted Negative
Actual Positive	True Positive (TP)	False Negative (FN)
Actual Negative	False Negative (FN)	True Negative (TN)

Tabel 1. Performansi

1. Presisi adalah rasio prediksi benar positif dibandingkan dengan semua hasil yang diprediksi positif oleh sistem. Secara matematis ditulis seperti pada Persamaan (6).

$$Presisi = \frac{TP}{TP + FP} \quad (6)$$

2. Recall adalah rasio prediksi benar positif dibandingkan dengan semua hasil yang benar positif. Secara matematis seperti pada Persamaan (7).

$$Recall = \frac{TP}{TP + FN} \quad (7)$$

3. F1-score adalah hasil benar positif dibandingkan dengan benar positif pada recall dan prediksi positif pada presisi. Secara matematis ditulis seperti pada Persamaan (8).

$$F1 - score = 2 * \frac{Recall * Presisi}{Recall + Presisi} \quad (8)$$

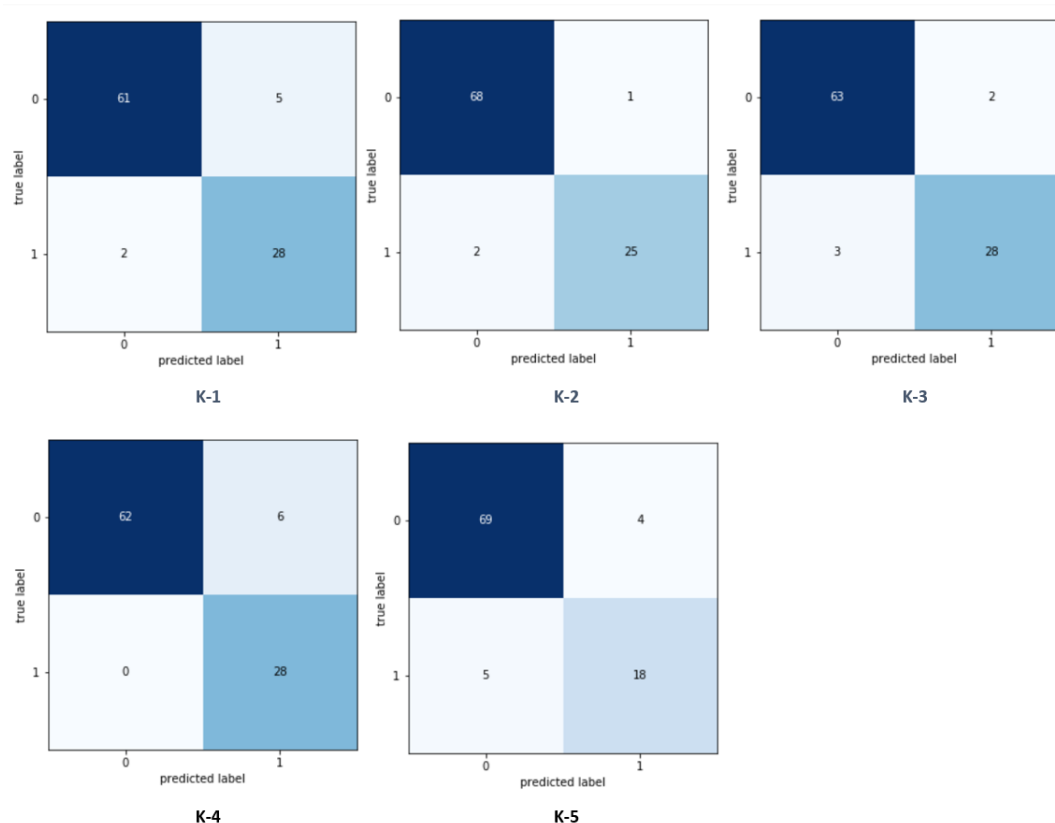
4. Akurasi adalah dilihat dari nilai benar positif dan benar negatif. Secara matematis ditulis seperti pada Persamaan (9).

$$Akurasi = \frac{TP + TN}{TP + TN + FP + FN} \quad (9)$$

4. Hasil Pengujian

K-Fold	Akurasi	Presisi	Recall	F1-Score
1	0,927	0,933	0,848	0,888
2	0,947	0,962	0,966	0,912
3	0,947	0,903	0,933	0,918
4	0,927	0,857	0,888	0,872
5	0,906	0,782	0,818	0,800

Tabel 2. Hasil Berdasarkan K-FOLD



Gambar 5. Confusion Matrix

Penelitian ini melatih model menggunakan *Artificial Neural Network* yang dimana menggunakan fungsi aktivasi sigmoid. Dari beberapa fungsi aktivasi yang ada, sigmoid dipilih dan digunakan karena sigmoid memiliki range 0 sampai 1 yang sesuai dengan output dari klasifikasi yaitu 0 sampai 1 yang dimana 0 artinya tidak macet, sedangkan 1 artinya macet. Apabila memakai fungsi aktivasi tanh atau relu, maka hasil performansi akan menurun drastis dikarenakan range relu antara 0 sampai tak hingga dan range tanh antara -1 sampai 1. K sebanyak 5 pada *cross-validation* akan meningkatkan efektifitas pada hasil performansi. Nilai random.state diisi sebanyak-banyaknya agar persebaran data saat *split* merata. Epoch ditentukan sebesar 300 kali agar meningkatkan akurasi uji serta akurasi latih. Pada sistem ini digunakan 1 hidden layer, karena apabila hidden layer lebih dari satu maka tidak mempengaruhi hasil melainkan hanya membebani proses komputasi.

Hasil dari model klasifikasi pada penelitian ini memiliki nilai performansi yang baik. Hasil performansi berdasarkan 5-fold dapat dilihat seperti pada Tabel 2. Berdasarkan tabel tersebut terlihat bahwa nilai akurasi apabila dirata-ratakan sebesar 0,931 yang artinya semakin besar nilai akurasi maka kinerja model pada klasifikasi kemacetan ini semakin bagus, lalu rata-rata nilai presisi sebesar 0,887 yang artinya semakin besar nilai presisi maka dalam memprediksi ketepatan total jumlah benar positif semakin bagus dalam klasifikasi kemacetan ini, kemudian rata-rata nilai recall sebesar 0,891 yang artinya memprediksi ketepatan jumlah total sebenarnya semakin bagus dalam klasifikasi kemacetan ini, serta rata-rata nilai f1-score sebesar 0,878 yang artinya semakin besar nilai f1 score maka semakin bagus hasil prediksi kedua kelas yang dihasilkan pada klasifikasi kemacetan ini. Pada kasus ini data yang diperoleh ialah data yang memiliki jumlah kelas yang tidak seimbang yaitu jumlah kelas negatif atau kelas 0 (tidak macet) lebih banyak dibandingkan dengan jumlah kelas positif atau kelas 1 (macet), sehingga hasil performansi pada kasus ini lebih mengutamakan nilai f1-score dibandingkan nilai akurasi, karena f1-score diperoleh dari hasil membandingkan antara output sebenarnya kelas positif, dengan output sebenarnya kelas positif pada recall dan output prediksi kelas positif pada presisi sehingga f1-score lebih baik performanya dibandingkan akurasi. Untuk lebih detailnya hasil *confusion matrix* dari model yang telah diuji dapat dilihat pada Gambar 5.

5. Kesimpulan

Pada penelitian ini telah berhasil dibangun sistem model klasifikasi kemacetan khususnya di persimpangan Buah Batu. Metode yang digunakan ialah *Artificial Neural Network* lalu menggunakan fungsi aktivasi sigmoid. Hasil performansi dihitung menggunakan 5-fold cross validation. Hasil diperoleh rata-rata akurasi sebesar 0,931

kemudian rata-rata presisi sebesar 0,887 lalu rata-rata recall sebesar 0,891 dan rata-rata f1-score sebesar 0,878. Hasil nilai F1-score 0,878 yang artinya semakin besar nilai f1 score maka semakin bagus hasil prediksi kedua kelas yang dihasilkan pada klasifikasi kemacetan ini, lalu hasil nilai akurasi 0,931 yang artinya semakin besar nilai akurasi maka kinerja model pada klasifikasi kemacetan ini semakin bagus.

Pada penelitian ini lebih diutamakan nilai F1-score dibandingkan nilai akurasi, karena pada penelitian ini memiliki data dengan jumlah kelas yang imbalance sehingga nilai F1-score lebih diutamakan, karena F1-score memiliki kemampuan dalam menilai model yang dibuat apakah kedua kelas diprediksi dengan baik atau tidak. Oleh karena itu diharapkan model klasifikasi ini dapat membantu dalam menentukan kontrol manajemen lalu lintas yang tepat untuk penanganan kemacetan di persimpangan Buah Batu, lalu model ini juga dapat dikembangkan lagi serta dapat digunakan untuk klasifikasi kemacetan pada persimpangan lainnya.

Daftar Pustaka

- [1] D. Andriawan. Pertumbuhan kendaraan di bandung 11 persen per tahun. <https://bandung.bisnis.com/read/20181002/549/1114194/pertumbuhan-kendaraan-di-bandung-11-per-tahun#>, 2018.
- [2] S. Golnaraghi and Z. Zangenehmadar. Application of artificial neural network(s) in predicting formwork labour productivity. 19, 2019.
- [3] Y. H. Laoly. *Peraturan Menteri Perhubungan Republik Indonesia*. Berita Negara Republik Indonesia, 2015.
- [4] A. Hermawan. *Jaringan Saraf Tiruan Teori dan Aplikasi*. ANDI OFFSET, 2006.
- [5] A. M, S. TEJA S. P, and D. N. Artificial neural networks: Functioning and applications in pharmaceutical industry. 10, 2018.
- [6] E. Pandu Cynthia and E. Ismanto. Jaringan syaraf tiruan algoritma backpropagation dalam memprediksi ketersediaan komoditi pangan provinsi riau. (9), 2017.
- [7] D. M. W. Powers. Evaluation: From precision, recall and f-measure to roc, informedness, markedness correlation. 2011.
- [8] L. Pujiawati. *Kota Bandung Dalam Angka*. Badan Pusat Statistika Kota Bandung, 2018.
- [9] D. Purwitasari, G. Edward, T. Aqdami Mukhtar, and J. Lianto Buliali. Algoritma komputasi cerdas untuk prediksi jumlah pengguna kendaraan sebagai indikator rawan macet. 14(1), 2016.
- [10] D. Puspitaningrum. *Pengantar Jaringan Saraf Tiruan*. ANDI OFFSET, 2006.
- [11] B. Rahayudi and R. Rizqiana Perdana Putri. Implementasi metode jst-backpropagation untuk klasifikasi rumah layak huni. *Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer*, 2(10):3360–3365, 2017.
- [12] J. Rodriguez, P. Aritz, and J. Lozano. Sensitivity analysis of k-fold cross validation in prediction error estimation. 2010.
- [13] A. Smith and Z. Sya'diyah. Peramalan jumlah kendaraan di dki jakarta dengan jaringan backpropagation. *Ilmu Matematika dan Terapan*, 10(2):117–123, 2017.
- [14] Suyanto. *Artificial Intelligence, Searching, Reasoning, Planning, and Learning*. Informatika, 2007.
- [15] T. Thamrin. Prediksi data arus lalu lintas di kabupaten jepara menggunakan algoritma neural network. 9(2), 2018.
- [16] C. T. Wawan, H. Kridalaksana A, and U. M.Irwan. Recognition of a human behavior pattern in paper rock scissor game using backpropagation artificial neural network method. 2014.